

Relatório do EP1 de classificação da clareza das respostas e SIC

ACH2118 — Processamento de Linguagem Natural

Modelo final: BERTimbau Base com ajuste fino para três classes de clareza.

1 Integrantes

Nome completo	Número USP
[NOME COMPLETO DO INTEGRANTE 1]	[NÚMERO USP]
[NOME COMPLETO DO INTEGRANTE 2]	[NÚMERO USP]

Substituir os campos acima pelos integrantes efetivos antes da entrega.

2 Estratégia e modelo final

A tarefa classifica cada resposta textual do e-SIC em c1, c234 ou c5. O modelo final é o BERTimbau Base (neuralmind/bert-base-portuguese-cased) com uma cabeça nova de classificação em três classes. O texto original da coluna resp_text é tokenizado pelo vocabulário do modelo; a sequência usa até 512 tokens, preservando o início quando precisa truncar. A classificação usa os logits da cabeça treinada.

A escolha foi fixada pela maior acurácia média em três folds internos agrupados. A diferença para a referência TF-IDF com regressão logística foi pequena; os dados observados não sustentam uma alegação de superioridade geral do BERTimbau.

3 Pré processamento

Todas as 20.092 linhas e seus rótulos originais foram mantidos, inclusive duplicatas e grupos com rótulos conflitantes. Não houve remoção de stopwords, URLs ou acentos, nem normalização do texto apresentado ao modelo. Valores não textuais em resp_text são convertidos em string. O tokenizer adiciona tokens especiais, trunca após 512 tokens e usa preenchimento dinâmico por lote.

Somente para formar grupos da divisão, cada texto foi convertido para Unicode NFC, casefold e espaços em branco colapsados; o SHA-256 desse texto normalizado identificou o grupo. Nenhum grupo aparece em treino e validação da mesma divisão.

4 Busca de parâmetros

Oito configurações foram comparadas em um subconjunto fixo do desenvolvimento. As duas melhores opções seguiram para a confirmação em três folds internos. A tabela mostra as dimensões da busca e os valores fixos relevantes.

Parâmetro	Valores examinados ou fixados
Representação	início; início + fim
Comprimento máximo	256; 512 tokens
Taxa de aprendizado	2×10^{-5} ; 3×10^{-5}
Otimizador e regularização	AdamW; weight decay 0,01
Tamanho do lote	microbatch 2; acumulação 4; efetivo 8
Seleção	maior acurácia de validação; macro F1 em empate exato

5 Valores finais

Representação do início com 512 tokens; taxa 2×10^{-5} ; AdamW com weight decay 0,01; semente 20260924; lote efetivo 8; 4.523 atualizações do otimizador, aproximadamente 1,80 época no conjunto completo. Não se usa scheduler, warmup, validação durante o ajuste final nem parada antecipada. A configuração completa e a revisão fixada do modelo base constam em `configs/bert_stage5_final.json`.

6 Divisão e procedimento

Um holdout externo de 3.024 respostas foi separado antes da seleção. As 17.068 respostas de desenvolvimento alimentaram três folds de StratifiedGroupKFold, com grupos disjuntos. O candidato escolhido obteve acurácia média de 45,007% e macro F1 média de 44,690% nesses folds. A referência TF-IDF, C=0,5, atingiu respectivamente 44,705% e 44,453%. A seleção precedeu a única auditoria no holdout.

Após a auditoria, o mesmo protocolo congelado treinou uma nova cabeça de classificação sobre todas as 20.092 respostas por 4.523 passos. Essa execução integral produziu o checkpoint usado para preencher o arquivo de teste. O checkpoint integral contém as linhas antes reservadas ao holdout; por isso a métrica do holdout pertence ao checkpoint de auditoria, treinado somente no desenvolvimento, e não deve ser atribuída ao checkpoint integral.

7 Resultados do modelo escolhido

A tabela apresenta somente o BERTimbau escolhido, avaliado uma vez no holdout externo de 3.024 respostas, antes do treinamento integral.

Métrica	Resultado
Acurácia	45,966%
Macro F1	44,523%
Recall c1 (n = 952)	51,261%
Recall c234 (n = 1.036)	24,131%
Recall c5 (n = 1.036)	62,934%

O baixo recall de c234 é a principal limitação. Numa comparação pareada adicional solicitada após a auditoria, o TF-IDF obteve 45,437% de acurácia e 45,056% de macro F1 no mesmo holdout. A vantagem de 0,529 ponto percentual do BERTimbau em acurácia corresponde a 16 acertos adicionais; o teste exato de McNemar resultou em $p = 0,590$. O arquivo `test1.xlsx` tem 900 respostas sem rótulos, portanto não permite calcular acurácia de teste.

8 Repositório de código

<https://github.com/Zennitte/ep1-claridade-esic-bertimbau>

O repositório público contém código, parâmetros congelados, versões e instruções. As planilhas, predições e pesos do modelo não são publicados.

9 Reprodução

1. Obter `train.xlsx` e `test1.xlsx` pelo canal autorizado da disciplina e posicioná-los na raiz do projeto. A planilha de treino esperada tem SHA-256
0e9219233664ac675fc47982bbc822acd3bb15d67fb7bfc26b67bec047e46818.

2. Preparar Python 3.14 e instalar as versões de requirements.lock.txt, com PyTorch ROCm compatível. O ambiente original foi Windows 11, Radeon RX 7600, PyTorch 2.13.0+rocm10.0.0 e Transformers 4.56.2.

3. Executar `python src/audit_and_split.py` para reconstruir a divisão e verificar os hashes esperados.

4. Executar `python src/run_stage6_final.py --run-id reproducao_01` para ajustar o modelo integral em GPU ROCm. A execução salva `models/bert_final/` e exige aproximadamente 57 minutos no ambiente original.

5. Executar `python src/predict_test_xlsx.py test1.xlsx test1_predito.xlsx --sheet test1 --device cuda`. O script preenche clarity na cópia e preserva `resp_text`.

A análise do holdout pode ser reproduzida com `src/run_stage5f_holdout_audit.py`, sempre antes do treino integral, conforme a configuração congelada. A inferência no teste não fornece métricas sem rótulos verdadeiros.